

Trabalho Prático

Diagnóstico de Osteoartrite Femorotibial através de imagens de raio X

Data de entrega: 13/10/2022 até às 08:00 (1ª parte) e 05/12/2022 até às 08:00 (trabalho completo) pelo Canvas

Valor: 35 pontos (10+25)


Penalidade por atraso: Valor total, não se admite atraso!

Grupos: 2 ou 3 componentes, cujos nomes devem ser informados por email em no máximo 15 dias para o sorteio do classificador.

Descrição:

A osteoartrite (artrose) é uma doença que se caracteriza pelo desgaste da cartilagem articular e por alterações ósseas nas articulações. O raio X é o principal exame para diagnóstico da doença que é classificada pela escala de Kellgren & Lawrence (KL), de acordo com o seu grau de severidade. O diagnóstico de artrose é confirmado para $KL > 1$.

Kellgren and Lawrence (KL) Grading System



Grade 0

No radiographic features of OA




Grade 1

Possible osteophytic lipping
Doubtful joint space narrowing (JSN)




Grade 2

Definite osteophytes
Possible JSN



Grade 3

Multiple osteophytes
Definite JSN
Sclerosis



Grade 4

Large osteophytes
Marked JSN
Severe sclerosis

Neste trabalho, você deverá implementar um aplicativo que leia imagens de raio X do joelho e possibilite o diagnóstico automático da osteoartrite femorotibial.

Dataset:

O conjunto de imagens a ser usado está disponível em

<https://data.mendeley.com/datasets/56rmx5bjcr/1>

Especificações do programa:

- O programa deve ser implementado em C, C++, Python 3.8 ou Java.
- É permitido o uso de funções elementares de bibliotecas mas o código principal deve ser original. Por função elementar entende-se uma função básica de manipulação de imagens, cujo resultado não seja a solução final do problema. Ex: leitura de arquivos, cálculo de histogramas, filtros, cálculo de distâncias, conversão entre formatos de imagens, cálculo de características, classificadores de uso geral.
- Todo arquivo enviado deve conter o nome, matrícula, curso e campus dos componentes do grupo.
- O código deve ser comentado. Códigos não comentados perdem 30% dos pontos
- Códigos copiados anulam o trabalho.
- Qualquer drive montado em nuvem deve ser alterado para diretórios locais, de forma que seja possível executar os programas localmente.
- O ambiente deve ser totalmente gráfico e deverá oferecer as seguintes opções acessadas por menus:

1ª parte:

- Ler e visualizar imagens nos formatos PNG e JPG. As imagens podem ter qualquer resolução e número de tons de cinza (normalmente variando entre 8 e 16 bits por pixel);
- Recortar uma sub-região de tamanho arbitrário com o mouse e salvá-la como arquivo.
- Buscar, em uma imagem qualquer, uma região previamente recortada ou lida de arquivo. Indicar com um retângulo a posição onde foi detectada. Uma técnica que pode ser usada para isso é a correlação cruzada:

$$CCN = \frac{1}{s_A s_B} \sum_{x,y} (A(x,y) - m_A)(B(x,y) - m_B)$$
$$m_I = \frac{1}{N} \sum_{x,y} I(x,y)$$
$$s_I = \sqrt{\sum_{x,y} (I(x,y) - m_A)^2}$$

onde A e B são a imagem e região buscada, com respectivos valores de intensidade médios (m) e desvios-padrões (s). O valor máximo de CCN indicará a posição mais provável de ocorrência de B em A.

2ª parte:

- Ler os diretórios onde estarão as imagens usadas para treino, validação e teste dos classificadores utilizados.
- Realizar aumento de dados através de espelhamento horizontal e equalização de histogramas.
- Especificar e treinar pelo menos 2 classificadores, exibindo-se o tempo de execução na interface:

- Classificador raso, exceto rede neural, utilizando características extraídas da imagem (projeções, textura, histogramas, descritores de forma, etc.)
- Rede neural convolucional sorteada para o grupo. Utilize os pesos disponíveis no modelo, retreinando a parte completamente conectada com o dataset de raio X.
- Classificar o conjunto de teste em 2 opções: classificação binária (normal x artrose) e com as 5 classes KL. O tempo de execução deve ser medido e exibido na interface, juntamente com a matriz de confusão e as métricas de sensibilidade, especificidade, precisão, acurácia e score F1.

A documentação **EM FORMATO PDF** deve ser na forma de um artigo, contendo:

- a) A descrição do problema.
- b) Descrição das técnicas implementadas para a solução, principalmente dos classificadores e descritores.
- c) As referências das bibliotecas utilizadas.
- d) As medidas de tempo de execução para diversas imagens, descritores e hiperparâmetros do classificador.
- e) Resultados obtidos nos testes, gráficos de convergência, exemplos de erros e acertos dos métodos.
- h) Discussão comparativa entre os resultados obtidos nos classificadores, justificativa e análise de todos os hiperparâmetros e estratégias usados na concepção do classificador, incluindo o controle de overfitting, underfitting e velocidade de convergência. Incluir uma **figura** com a topologia da rede mais eficaz e uma **comparação** de resultados intermediários obtidos no processo de ajuste de hiperparâmetros. A nota será proporcional ao esforço empenhado no ajuste e **qualidade da análise**.
- f) Referências bibliográficas.

O que entregar:

Arquivos fontes e documentação. Coloque todos os arquivos na raiz de um diretório cujo nome deve ser o número de matrícula de um dos componentes. Comprima o diretório e poste no Canvas até a hora especificada para cada parte. O tamanho total dos arquivos não deve ultrapassar 5 Mbytes (não envie imagens!).

Obs: Trabalhos de qualidade superior poderão ganhar pontos extras.

Artigo de referencia:

Pingjun Chen, Linlin Gao, Xiaoshuang Shi, Kyle Allen, Lin Yang. “Fully automatic knee osteoarthritis severity grading using deep neural networks with a novel ordinal loss”. *Computerized Medical Imaging and Graphics* **75**:84-92, 2019.